

计算机

国内 AI 的黄金周

阿里巴巴：大模型是下一代操作系统，通义千问以开源模式打造 AI 时代的 Android。 9 月 24 日阿里巴巴召开的云栖大会上，阿里巴巴集团 CEO、阿里云智能集团董事长兼 CEO 吴泳铭发表主旨演讲，阿里巴巴判断，大模型是下一代的操作系统。基于这个判断，阿里做出战略选择：通义千问选择开放路线，打造 AI 时代的 Android。通义千问系列已实现全尺寸、全模态、多场景模型布局，其中最新亮相的阿里通义旗舰模型 Qwen3-Max，性能超过 GPT5、Claude Opus 4 等，跻身全球前三。

腾讯：混元图像 3.0 发布，业界首个开源工业级原生多模态生图模型。 2025/9/28，混元图像 3.0 (HunyuanImage 3.0) 发布，这是首个工业级原生多模态生图模型，参数规模 80B，也是目前测评效果最好、参数量最大的开源生图模型，具备语言模型的思考能力和常识，效果可对标业界头部闭源模型。文生图技术范式从 DiT 转向原生多模态构架，混元图像 3.0 是以混元 LLM 为基础混合训练得到的成果。展望未来，腾讯混元团队透露，混元图像 3.0 目前的版本仅开放了文生图能力，图生图、图像编辑、多轮交互等版本将于后续发布。


DeepSeek:v3.2 架构创新，国产算力协同适配。 9 月 29 日 DeepSeek-V3.2-Exp 模型发布。引入了 DeepSeek Sparse Attention (一种稀疏注意力机制)，在几乎不影响模型输出效果的前提下，实现了长文本训练和推理效率的大幅提升；新模型服务成本的大幅降低，官方百万 token 的输入价格 4 元->2 元 (缓存未命中)/0.5 元->0.2 元 (缓存命中)，输出价格 12 元->3 元。开源 TileLang 与 CUDA 两种版本算子方便社区调试和快速迭代。当日寒武纪与昇腾均实现对 DeepSeek-V3.2-Exp 的适配，寒武纪开源了大模型推理引擎 vLLM-MLU 源代码。

华为：余承东掌舵华为 IRB，主导 AI 战略全产业链攻坚。 9 月 29 日余承东出任华为投资评审委员会 (IRB) 主任，任命文件由任正非亲自签发。余承东将主导华为 IRB，其核心任务是带领华为在人工智能领域取得全球领先地位，被内部视为“打赢 AI 关键战役”的核心领导人。在计算基础设施方面，华为形成了基于鲲鹏的通用算力以及基于昇腾的智能算力的算力体系。2025 年华为全联接大会上，华为发布全球最强算力超节点和集群，Atlas 950 SuperPoD 和 Atlas 960 SuperPoD 超节点分别支持 8192 及 15488 张昇腾卡，在卡规模、总算力、内存容量、互联带宽等关键指标上全面领先；全球最强超节点集群 Atlas 950 SuperCluster 和 Atlas 960 SuperCluster 算力规模分别为超过 50 万卡和百万卡，成为全球最强算力集群之一。

快手：可灵 2.5 Turbo 全方位升级，OpenAI 推出 Sora APP 开启 AI 视频商业化新空间。 9 月 29 日可灵 2.5 Turbo 发布，稳定性&想象力全方位升级，视频效果再次超世代，同时定价下调 30%。与 Veo 3 Quality、Veo 3 Fast、Seedance 1.0、Seedance 1.0 mini 等模型进行了效果对比，可灵 2.5 Turbo 的效果表现超过了所有其他模型。9 月 30 日 OpenAI 推出了新的视频生成模型 Sora 2，比之前的系统更加物理精准、逼真，并且更易于控制，还支持同步对话和音效。同时推出了 Sora APP，借助这款新应用，OpenAI 在向打造社交媒体产品迈出一大步，可能开启新的广告收入来源。Sora APP 的‘客串’功能允许用户把自己插入视频。我们认为 OpenAI 的

增持 (维持)

行业走势



作者

分析师 刘高畅

执业证书编号: S0680518090001

邮箱: liugaochang@gszq.com

相关研究

- 1、《计算机：数币迎重大落地事件，政策暖意初现》 2025-09-28
- 2、《计算机：第七次谈自定义 Agent》 2025-09-27
- 3、《计算机：第六次谈自定义 Agent》 2025-09-20

Sora APP 是对视频生成模型商业化变现的重要探索,有望改变未来社交平台的内容生态。快手的可灵模型性能优秀,也有望打开新的商业化成长空间。

建议关注

算力: 寒武纪、海光信息、东阳光、新易盛、中芯国际、华虹半导体、胜宏科技、鸿腾精密科技、有方科技、协创数据、中际旭创、沪电股份、兴森科技、中科曙光、浪潮信息、东山精密、伟仕佳杰、宏景科技、奥飞数据、云赛智联、科华数据、禾盛新材、潍柴重机、金山云、浙数文化、青云、大位科技、玉柴国际、亿田智能、弘信电子、圣阳股份、润泽科技、润建股份、深信服、神州数码、深桑达、品高股份、云天励飞、优刻得、云从科技、太极股份、数据港、首都在线。

Agent: 阿里巴巴、腾讯控股、拓尔思、阜博集团、第四范式、快手、美图公司、金蝶国际、金山办公、金桥信息、鼎捷数智、慧辰股份、嘉和美康、海天瑞声、泛微网络、税友股份、朗新集团、壹网壹创、润达医疗、360、万兴科技、用友网络、麦迪科技、宇信科技、京北方、中科金财、致远互联、汉得信息、软通动力、光云科技、上海钢联、新致软件、同花顺、信雅达、萤石网络、迪安诊断、中科金财、恒生电子、星环科技、卫宁健康、创业慧康、科大讯飞、万兴科技、创业黑马、迈富时、小商品城、金证股份、顶点软件、朗新集团、晶泰控股、佳发教育、新大陆、新开普等。

自动驾驶: 江淮汽车、赛力斯、小鹏汽车、理想汽车、禾赛、地平线、世运电路等。

军工 AI: 拓尔思、能科科技、普天科技、品高股份、海格通信、中科星图等。

风险提示: 技术迭代不及预期、经济下行超预期、行业竞争加剧。

内容目录

1.国内 AI 巨头新进展不断，AI 全产业链持续突破..... 4

2.阿里：Qwen 家族实现模型体系全面生态，算力加码凸显重视力度 5

3.腾讯：混元图像 3.0 发布，业界首个开源工业级原生多模态生图模型11

4.DeepSeek: v3.2 架构创新，国产算力协同适配14

5.华为：余承东掌舵华为 IRB，主导 AI 战略全产业链攻坚15

6 快手：可灵 2.5 Turbo 全方位升级，OpenAI 推出 Sora APP 开启 AI 视频商业化新空间16

建议关注20

风险提示20

图表目录

图表 1: AI 巨头产业进展 4

图表 2: 通义千问 Qwen 模型家族全景 8

图表 3: Qwen3-Max 性能跻身全球前三 9

图表 4: 阿里云是全球领先的全栈 AI 服务商11

图表 5: 腾讯混元图像 3.0 模型的特性.....12

图表 6: 腾讯混元图像 3.0 模型应用案例 1: 月全食四格漫画.....13

图表 7: 腾讯混元图像 3.0 模型应用案例 2: 穿搭博主衣物生成.....13

图表 8: DeepSeek-V3.2-Exp 与 V3.1-Terminus 不同长度位置 Token 的推理成本对比14

图表 9: 华为 Atlas 950 SuperPoD 超节点16

图表 10: 可灵 2.5 Turbo 文生视频和图生视频效果胜负比17

图表 11: Sora APP.....18

图表 12: Sora APP 可以生成与朋友扳手腕的 AI 视频19

1.国内 AI 巨头新进展不断，AI 全产业链持续突破

图表1: AI 巨头产业进展

	人才战略	算力布局	模型进展	应用落地
deepseek	和大厂团队相比规模更精炼，喜欢“高潜力年轻人”，员工规模不到 140 人，是 Open AI 的十分之一左右。多毕业于北大、清华、中科大等国内顶尖院校，也有少数毕业于海外知名高校。员工中有相当一部分具有交叉学科背景。	与寒武纪、昇腾深度合作，快速适配	DeepSeek-V3.2-Exp 实现长文本训练和推理效率的大幅提升	开源 TileLang & CUDA 算子帮助用户调试和快速迭代。模型降本利于应用落地
阿里	2026 届校招中 80% 为 AI 岗位，包括 AI 算法、研发、AI 产品经理等。同时阿里国际首次启动了一项面向全球的头部 AI 科技人才培养计划——“Bravo 102”，打破传统的校招体系，面试通过后可选项目和团队。	9 月 16 日新闻联播首次揭露阿里自研 AI 芯片平头哥 PPU，分为基础版与高级版，基础版专注 AI 推理，峰值算力达 120TFLOPS 云栖大会宣布积极推进三年 3800 亿的 AI 基础设施建设计划，并将会持续追加更大的投入，2032 年阿里云全球数据中心的能耗规模将对比 2022 年提升 10 倍。	云栖大会上，通义大模型 7 连发，在模型智能水平、Agent 工具调用和 Coding 能力、深度推理、多模态等方面实现多项突破。Qwen 模型家族开源生态全球第一，17 万+全球衍生模型，全球下载量 6 亿+	高德地图全面 AI 化，推出首个基于用户行为产生的榜单“高德扫街榜”；钉钉最新完成 AI 升级，打造全球首个以 Agent 驱动的工作信息流；淘宝平台也实现 AI 搜索、AI 广告平台等一系列 AI 应用升级；支付宝推出 AI 生活管家 App “支小宝”和智能体开发平台“百宝箱”。
腾讯	4 月 29 日，腾讯宣布混元新成立了大语言模型部和多模态模型部；同时将大数据、机器学习平台部、AI Lab、安全平台部、信息安全部等几个部门，重组为数据平台部、机器学习平台部两个部门，构建技术底座，为混元大模型训练提供算力与数据支撑——新成立的多个部门负责人均向混元大模型负责人、腾讯公司副总裁蒋杰汇报。此前混元团队是	芯片方面腾讯投资燧原科技（持股 20.4944%）腾讯云计划在沙本新建数据中心，目前，腾讯云已在雅加达、新加坡、法兰克福等地布局 9 大技术支持中心	混元 3D 3.0 基模建模精度提升 3 倍，可广泛应用于游戏开发、动画制作、工业设计等场景 日发布的混元图像 3.0 是首个工业级原生多模态生图模型，参数规模 80B，也是目前测评效果最好、参数量最大的开源生图模型	据 9 月腾讯数字生态大会，AI 带来的增长在腾讯业务中加速兑现： 腾讯元宝跻身国内 AI 原生应用 DAU 前 ima 沉淀了超 1 亿的知识库文件； QQ 浏览器 AI 月活比 4 月增长 17.8 倍； 近 1 年腾讯会议 AI 功能用户量同比增长 150%。

以虚拟组织的形式，横跨在 TEG 的大数据、机器学习平台部、AI Lab 等多个部门中。

华为

9月29日余承东出任华为投资评审委员会（IRB）主任，任命文件由任正非亲自签发。余承东将主导华为 IRB，其核心任务是带领华为在人工智能领域取得全球领先地位，被内部视为“打赢 AI 关键战役”的核心领导人。

计算基础设施方面，华为形成了基于鲲鹏的通用算力以及基于昇腾的智能算力的算力体系。2025 年华为全联接大会上，发布全球最强算力超节点和集群，Atlas 950 SuperCluster 和 Atlas 960 SuperCluster 算力规模分别为超过 50 万卡和百万卡

在华为开发者大会 2025 上发布盘古大模型 5.5，在自然语言处理，多模态等 5 大基础模型全面升级

端侧 AI 方面，“天工计划”承诺投入 10 亿元扶持鸿蒙 AI 生态创新，激励超过 1 万个 AI 原生元服务与 5000+智能体的孵化。鸿蒙 5 终端设备已突破 2000 万。鸿蒙智行 8 月销量约 4.6 万辆，前 8 个月累计销量约为 29.6 万辆。目前华为合作的车企包括赛力斯、奇瑞、北汽、江淮以及上汽等

资料来源：各公司官网及公众号、腾讯云公众号、今日头条、新浪财经、证券时报、环球网、国盛证券研究所

2.阿里：Qwen 家族实现模型体系全面生态，算力加码凸显重视力度

阿里云栖大会一系列重磅发布，AI 生态布局全景展现。2025 年 9 月 24 日，在阿里巴巴召开的云栖大会上，阿里巴巴集团 CEO、阿里云智能集团董事长兼 CEO 吴泳铭发表主旨演讲，展示了阿里巴巴集团对于人工智能的核心观点，以及公司在人工智能领域的全生态链布局。具体内容如下：

AI 终极目标是发展出能自我迭代、全面超越人类的超级人工智能 ASI

阿里巴巴认为实现通用人工智能 AGI 已是确定性事件，但这只是起点，终极目标是发展出能自我迭代、全面超越人类的超级人工智能 ASI。AGI 的目标是将人类从 80% 的日常工作中解放出来，让人类专注于创造与探索。而 ASI 作为全面超越人类智能的系统，将可能创造出一批“超级科学家”和“全栈超级工程师”。ASI 将以难以想象的速度，解决现在未被解决的科学和工程问题，比如攻克医学难题、发明新材料、解决可持续能源和气候问题，甚至星际旅行等等。ASI 将以指数级的速度推动科技的飞跃，引领人类进入一个前所未有的智能时代。

通往 ASI 之路将经历三个阶段：

1) 第一阶段是“智能涌现”，特征是“学习人”。过去几十年的互联网发展，为智能涌现提供了基础。互联网将人类历史上几乎所有的知识都数字化了。这些语言文字承载的信息，代表了人类知识的全集。基于此，大模型首先通过理解全世界的知识集合，具备了泛化的智能能力，涌现出通用对话能力，可以理解人类的意图，解答人类的问题，并逐渐发展出思考多步问题的推理能力。

2) 第二个阶段是“自主行动”，特征是“辅助人”。这个阶段，AI 不再局限于语言交流，而是具备了在真实世界中行动的能力。AI 可以在人类的目标设定下，拆解复杂任务，使

用和制作工具，自主完成与数字世界和物理世界的交互，对真实世界产生巨大影响。这正是人类当下所处的阶段。

实现这一跨越的关键，首先是大模型具备了 **Tool Use** 能力，有能力连接所有数字化工具，完成真实世界任务。人类加速进化的起点是开始创造和使用工具，现在大模型也具备了使用工具的能力。通过 **Tool Use**, AI 可以像人一样调用外部软件、接口和物理设备，执行复杂的真实世界任务。

其次，大模型 **Coding** 能力的提升，可以帮助人类解决更复杂的问题，并将更多场景数字化。现在的 **Agent** 还比较早期，解决的主要是标准化和短周期的任务。要想让 **Agent** 能解决更复杂、更长周期任务，最关键的是大模型的 **Coding** 能力。因为 **Agent** 可以自主 **Coding**，理论上就能解决无限复杂的问题，像工程师团队一样理解复杂需求并自主完成编码、测试。发展大模型 **Coding** 能力是通往 **AGI** 的必经之路。

未来，自然语言就是 **AI** 时代的源代码，任何人用自然语言就能创造自己的 **Agent**。只需要输入母语，告诉 **AI** 你的需求，**AI** 就能自己编写逻辑、调用工具、搭建系统，完成数字世界的几乎所有工作，并通过数字化接口来操作所有物理设备。

2) 随后 AI 将进入第三个阶段——“自我迭代”，特征是“超越人”。这个阶段有两个关键要素：

第一、AI 连接了真实世界的全量原始数据

目前 **AI** 的进步最快的领域是内容创作、数学和 **Coding** 领域。阿里看到这三个领域有明显的特征：这些领域的知识 100% 是人类定义和创造的，都在文字里，**AI** 可以 100% 理解原始数据。但是对于其他领域和更广泛的物理世界，今天的 **AI** 接触到的更多是人类归纳之后的知识，缺乏广泛的、与物理世界交互的原始数据。这些信息是有局限的。

AI 要实现超越人类的突破，就需要直接从物理世界获取更全面、更原始的数据。简单的例子，比如一家汽车公司的 **CEO** 要迭代明年的产品，大概率会通过无数次的用户调研或者内部的讨论来决定下一款汽车将要具备什么样的功能，与竞对相比要实现哪些方面的长板，保留什么方面的能力。现在 **AI** 要去做还是很难的，核心点在于它所获得的数据和信息，全都是调研来的二手数据。如果有一天 **AI** 有机会，能够连接这款汽车的所有资料和数据，它创造出来的下一款汽车会远远超过通过无数次头脑风暴所创作出来的。这只是人类世界其中的一个例子，更何况更复杂的物理世界，远远不是通过人类知识归纳就能够让 **AI** 理解的。

第二、Self-learning 自主学习

随着 **AI** 渗透更多的物理世界场景，理解更多物理世界的数据，**AI** 模型和 **agent** 能力也会越来越强，有机会为自己模型的升级迭代搭建训练 **infra**、优化数据流程和升级模型架构，从而实现 **Self learning**。这会是 **AI** 发展的关键时刻。

随着能力的持续提升，未来的模型将通过与真实世界的持续交互，获取新的数据并接收实时反馈，借助强化学习与持续学习机制，自主优化、修正偏差、实现自我迭代与智能升级。每一次交互都是一次微调，每一次反馈都是一次参数优化。当经过无数次场景执行和结果反馈的循环，**AI** 将自我迭代出超越人类的智能能力，一个早期的超级人工智能（**ASI**）便会成型。

大模型是下一代操作系统，通义千问以开源模式打造 AI 时代的 Android

阿里巴巴判断，大模型是下一代的操作系统。阿里认为，大模型代表的技术平台将会替代现在 OS 的地位，成为下一代的操作系统。未来，几乎所有链接真实世界的工具接口都将与大模型进行链接，所有用户需求和行业应用将会通过大模型相关工具执行任务，LLM 将会是承载用户、软件与 AI 计算资源交互调度的中间层，成为 AI 时代的 OS。


来做一些简单的类比：自然语言是新的编程语言，Agent 就是新的软件，Context 是新的 Memory，大模型通过 MCP 这样的接口，连接各类 Tools 和 Agent 类似 PC 时代的总线接口，Agent 之间又通过 A2A 这样的协议完成多 Agent 协作类似软件之间的 API 接口。

大模型作为下一代的操作系统，将允许任何人用自然语言，创造无限多的应用。未来几乎所有与计算世界打交道的软件可能都是由大模型产生的 Agent，而不是现在的商业软件。潜在的开发者的数量将从几千万变成数亿规模。以前由于软件开发的成本问题，只有少量高价值场景才会被工程师开发出来变成商业化的软件系统。未来所有终端用户都可以通过大模型这样的工具来满足自己的需求。

正是基于这个判断，阿里做出战略选择：通义千问选择开放路线，打造 AI 时代的 Android。阿里认为在 LLM 时代，开源模型创造的价值和能渗透的场景，会远远大于闭源模型。阿里坚定选择开源，就是为了全力支持开发者生态，与全球所有开发者一起探索 AI 应用的无限可能。

通义千问系列已实现全尺寸、全模态、多场景模型布局。云栖大会上，通义大模型 7 连发，在模型智能水平、Agent 工具调用和 Coding 能力、深度推理、多模态等方面实现多项突破。其中：

图表2: 通义千问 Qwen 模型家族全景




资料来源: 阿里云云栖大会官方公众号, 国盛证券研究所

● Qwen3-Max 性能跻身全球前三

在大语言模型中, 阿里通义旗舰模型 Qwen3-Max 全新亮相, 性能超过 GPT5、Claude Opus 4 等, 跻身全球前三。Qwen3-Max 包括指令 (Instruct) 和推理 (Thinking) 两大版本, 其预览版已在 Chatbot Arena 排行榜上位列第三, 正式版性能可望再度实现突破。

Qwen3-Max 是通义千问家族中最大、最强的基础模型, 预训练数据量达 36T tokens, 总参数超过万亿, 拥有极强的 Coding 编程能力和 Agent 工具调用能力。在大模型用 Coding 解决真实世界问题的 SWE-Bench Verified 测试中, Instruct 版本斩获 69.6 分, 位列全球第一梯队; 在聚焦 Agent 工具调用能力的 Tau2-Bench 测试中, Qwen3-Max 取得突破性的 74.8 分, 超过 Claude Opus4 和 DeepSeek-V3.1。

图表3: Qwen3-Max 性能跻身全球前三



资料来源: 阿里云云栖大会官方公众号, 国盛证券研究所

● Qwen3-Next 及系列模型正式发布

下一代基础模型架构 Qwen3-Next 及系列模型正式发布, 模型总参数 80B 仅激活 3B, 性能即可媲美千问 3 旗舰版 235B 模型, 实现模型计算效率的重大突破。Qwen3-Next 针对大模型在上下文长度和总参数两方面不断扩展 (Scaling) 的未来趋势而设计, 创新改进采用了混合注意力机制、高稀疏度 MoE 结构、多 token 预测 (MTP) 机制等核心技术, 模型训练成本较密集模型 Qwen3-32B 大降超 90%, 长文本推理吞吐量提升 10 倍以上, 为未来大模型的训练和推理的效率设立了全新标准。

● Qwen3-Coder 重磅升级

在专项模型方面, 千问编程模型 Qwen3-Coder 重磅升级。新的 Qwen3-Coder 与 Qwen Code、Claude Code 系统联合训练, 应用效果显著提升, 推理速度更快, 代码安全性也显著提升。Qwen3-Coder 此前就广受开发者和企业好评, 代码生成和补全能力极强, 可一键完成完整项目的部署和问题修复, 开源后调用量曾在知名 API 调用平台 OpenRouter 上激增 1474%, 位列全球第二。

● 视觉理解模型 Qwen3-VL 重磅开源

在多模态模型中, 千问备受期待的视觉理解模型 Qwen3-VL 重磅开源, 在视觉感知和多模态推理方面实现重大突破, 在 32 项核心能力测评中超过 Gemini-2.5-Pro 和 GPT-5。

全模态模型 Qwen3-Omni 亮相

全模态模型 Qwen3-Omni 惊喜亮相, 音视频能力狂揽 32 项开源最佳性能 SOTA, 可像人类一样听说写, 应用场景广泛, 未来可部署于车载、智能眼镜和手机等。用户还可设定个性化角色、调整对话风格, 打造专属的个人 IP。

● 通义万相推出 Wan2.5-preview 系列模型

通义万相推出 Wan2.5-preview 系列模型，涵盖文生视频、图生视频、文生图和图像编辑四大模型。通义万相 2.5 视频生成模型能生成和画面匹配的人声、音效和音乐 BGM，首次实现音画同步的视频生成能力，进一步降低电影级视频创作的门槛。

通义万相 2.5 视频生成时长从 5 秒提升至 10 秒，支持 24 帧每秒的 1080P 高清视频生成，并进一步提升模型指令遵循能力。此次，通义万相 2.5 还全面升级了图像生成能力，可生成中英文文字和图表，支持图像编辑功能，输入一句话即可完成 P 图。

● 语音大模型通义百聆正式发布

2025 杭州云栖大会上，通义大模型家族还迎来了全新的成员——语音大模型通义百聆，包括语音识别大模型 Fun-ASR、语音合成大模型 Fun-CosyVoice。Fun-ASR 基于数千万小时真实语音数据训练而成，具备强大的上下文理解能力与行业适应性；Fun-CosyVoice 可提供上百种预制音色，可以用于客服、销售、直播电商、消费电子、有声书、儿童娱乐等场景。

超级 AI 云是下一代的计算机，阿里算力布局持续加码

阿里认为，大模型是运行于 AI Cloud 之上新的 OS，超级 AI 云是下一代的计算机。这个 OS 可以满足任何人的需求。每个人都将拥有几十甚至上百个 Agent，这些 Agent 24 小时不间断地工作和协同，需要海量的计算资源。数据中心内的计算范式也在发生革命性改变，从 CPU 为核心的传统计算，正在加速转变为以 GPU 为核心的 AI 计算。新的 AI 计算范式需要更稠密的算力、更高效的网络、更大的集群规模。这一切都需要充足的能源、全栈的技术、数百万计的 GPU 和 CPU，协同网络、芯片、存储、数据库高效运作，并且 24 小时处理全世界各地的需求。这需要超大规模的基础设施和全栈的技术积累，只有超级 AI 云才能够承载这样的海量需求。未来，全世界可能只会有 5-6 个超级云计算平台。


阿里云定位为全栈人工智能服务商，是全球少数能做到软硬件垂直整合的超级 AI 云计算平台之一。在这个崭新的时代，阿里云的定位是全栈人工智能服务商，提供世界领先的智能能力和遍布全球的 AI 云计算网络，向全球各地提供开发者生态友好的 AI 服务。

1) 首先，阿里拥有全球领先的大模型——通义千问。通义千问开源了 300 多款模型，覆盖了全模态、全尺寸，是最受全球开发者欢迎的开源模型。截至目前，通义千问全球下载量超 6 亿次，衍生模型超 17 万个，是全球第一的开源模型矩阵，可以说是渗透计算设备最广泛的大模型。2) 同时，阿里云提供一站式模型服务平台百炼，支持模型定制化以及 Agent 快速开发，同时提供 AgentBay 这样的 Agent 运行环境、灵码/Qoder 等一系列开发者套件，让开发者可以方便地使用模型能力和创建使用 Agent。3) 阿里云运营着中国第一、全球领先的 AI 基础设施和云计算网络，是全球少数能做到软硬件垂直整合的超级 AI 云计算平台之一。在硬件和网络层面，阿里云自研的核心存储系统、网络架构、计算芯片，构成了阿里云大型计算集群最坚实的底座。

加码算力建设，2032 年阿里云全球数据中心的能耗规模将对比 2022 年提升 10 倍。

AI 行业发展的速度远超阿里的预期，行业对 AI 基础设施的需求也远超当前的预期。阿里正在积极推进三年 3800 亿的 AI 基础设施建设计划，并将会持续追加更大的投入。阿里正在全力打造一台全新的 AI 超级计算机，它同时拥有最领先的 AI 基础设施和最领先的模型，可以在基础架构设计和模型架构上协同创新，从而确保在阿里云上调用和训练大模型时，能达到最高效率，成为开发者最优选的。为了迎接 ASI 时代的到来，对比 2022 年这个 GenAI 的元年，2032 年阿里云全球数据中心的能耗规模将提升 10 倍。这是阿里的远期规划，公司相信通过这样的饱和式投入，能够推动 AI 行业的发展，迎接 ASI 时代的到来。

图表4: 阿里云是全球领先的全栈 AI 服务商



资料来源：阿里云栖大会官方公众号，国盛证券研究所

3. 腾讯：混元图像 3.0 发布，业界首个开源工业级原生多模态生图模型

腾讯发布混元图像 3.0 模型，效果可对标业界头部闭源模型。2025/9/28，混元图像 3.0（HunyuanImage 3.0）发布，这是首个工业级原生多模态生图模型，参数规模 80B，也是目前测评效果最好、参数量最大的开源生图模型，效果可对标业界头部闭源模型。它具备以下特性：

- 拥有“常识”，并能够利用知识进行推理
- 语义理解准确度高，并具备极致美学质感，能生成真实的高质感图片
- 可以解析千字级别的复杂语义，生成长文本文字和小文字
- 整体图像生成效果业界领先


图表5: 腾讯混元图像 3.0 模型的特性



资料来源: 腾讯开源官方公众号, 国盛证券研究所

混元图像 3.0 是业界首个开源的工业级原生多模态生图模型, 具备语言模型的思考能力和常识。原生多模态, 这指的是在技术架构上, 通过一个模型完成文字、图片、视频与音频等多个模态的输入与输出, 而非通过多个模型的组合实现图文理解、图片生成等任务。这意味着, 混元图像 3.0 不仅拥有生图模型的画画能力, 还具备语言模型的思考能力和常识。它就像一个自带“大脑”的画家, 可以利用智能去思考图像的布局、构图、笔触, 利用世界知识去推理常识性的画面。比如, 用户只需要输入提示词: “生成一个月全食的四格科普漫画”, 模型就可以自主生成完整的月全食科普, 无需用户描述逐格内容。

图表6: 腾讯混元图像 3.0 模型应用案例 1: 月全食四格漫画



资料来源: 腾讯开源官方公众号, 国盛证券研究所

同时, 混元图像 3.0 语义理解能力和美学质感也得到了大幅提升, 可以实现对用户指令的精确生成, 包括图片中的小字和长文本生成, 都能较好地实现。

比如输入: “你是一个小红书穿搭博主, 请根据模特穿搭生成一张封面图片, 要求: 1. 画面左侧是模特的 OOTD 全身图 2. 右侧是衣服的展示, 分别是上衣深棕色夹克、下装黑色百褶短裙、棕色靴子、黑色包包 风格: 实物摄影, 要求真实, 有氛围感, 秋季美拉德色系穿搭”。

在这个提示词下, 混元图像 3.0 可以准确地把左侧博主的穿搭分解成右侧单独的衣物。

图表7: 腾讯混元图像 3.0 模型应用案例 2: 穿搭博主衣物生成



资料来源: 腾讯开源官方公众号, 国盛证券研究所

可以看到，混元图像 3.0 不仅能生成复杂文本、复杂漫画、表情包，还能生成生动有趣的科普插画。这些能力能够大幅提升插画师、设计师等视觉创作者的效率，原来可能需要画几个小时的漫画，现在可能只需要几分钟就能实现；同时，没有美术功底和设计经验的内容创作者，也能创作出更丰富、生动的视觉内容。行业与学界研究者、企业与个人开发者，均可基于混元图像 3.0 进行应用研发或二次开发，制作相关衍生模型。


文生图技术范式从 DiT 转向原生多模态构架，混元图像 3.0 是以混元 LLM 为基础混合训练得到的成果。在文生图领域，当前学术界和业界正在从传统 DiT 转向原生多模态模型架构。当前业界已经有一些开源的模型，但都是小模型，偏向于学术研究和实验阶段，生图效果也离工业界最优效果有较大差距。作为原生多模态开源模型，混元图像 3.0 需要对模型整体架构进行重构，以支持多任务的训练，并实现多任务效果之间的相互促进。混元图像 3.0 以 Hunyuan-A13B 为基础，基于 50 亿量级的图文对，视频帧，图文交织数据和 6T 的语料数据进行了多模态生成、理解和 LLM 的混合训练，使得模型能够充分融合多任务效果，实现超强的语义理解能力，能够响应复杂的长文本，生成长文本文字，同时具有 LLM 的世界知识，能够利用世界知识进行推理。

展望未来，腾讯混元团队透露，混元图像 3.0 目前的版本仅开放了文生图能力，图生图、图像编辑、多轮交互等版本将于后续发布。

4. DeepSeek: v3.2 架构创新，国产算力协同适配

9 月 29 日 DeepSeek-V3.2-Exp 模型发布。作为迈向新一代架构的中间步骤，引入了 DeepSeek Sparse Attention（一种稀疏注意力机制），在几乎不影响模型输出效果的前提下，实现了长文本训练和推理效率的大幅提升。

图表8: DeepSeek-V3.2-Exp 与 V3.1-Terminus 不同长度位置 Token 的推理成本对比



资料来源: DeepSeek 公众号, 国盛证券研究所

得益于新模型服务成本的大幅降低，官方 API 价格也相应下调，百万 token 的输入价格 4 元→2 元（缓存未命中）/0.5 元→0.2 元（缓存命中），输出价格 12 元→3 元。在新的价格政策下，开发者调用 DeepSeek API 的成本将降低 50% 以上。

TileLang & CUDA 算子开源。在新模型的研究过程中，需要设计和实现很多新的 GPU 算子。DeepSeek 使用高级语言 TileLang 进行快速原型开发，以支持更深入的探索。在

最后阶段，以 TileLang 作为精度基线，逐步使用底层语言实现更高效的版本。因此，本次开源的主要算子包含 TileLang 与 CUDA 两种版本。DeepSeek 建议社区在进行研究性实验时，使用基于 TileLang 的版本以方便调试和快速迭代。

当日寒武纪与昇腾均已实现对 DeepSeek-V3.2-Exp 的适配，寒武纪开源了大模型推理引擎 vLLM-MLU 源代码。昇腾针对 DeepSeek-V3.2-Exp 架构中两个全新的算子针对性地进行算子 Tiling 设计、Cube 核与 Vector 核间的流水优化、计算流程的实现优化等，模型和融合 Kernel 均已开源。

我们认为 deepseek 的架构创新以及国产算力的迅速适配彰显国内 AI 软硬件实力，模型大幅降本有利于 AI 应用加速落地，day 0 适配和优化彰显了国产芯片的生态建设和技术积累成果，芯片和算法的联合创新，软硬件协同方式将进一步加速国内 AI 产业发展。

5. 华为：余承东掌舵华为 IRB，主导 AI 战略全产业链攻坚

据科创板日报，9 月 29 日余承东出任华为投资评审委员会（IRB）主任，任命文件由华为创始人任正非亲自签发。该委员会负责对公司重大战略方向的资源投入、项目立项及预算审批进行关键决策，确保资源高效聚焦核心战略目标。而余承东将主导华为 IRB，其核心任务是带领华为在人工智能领域取得全球领先地位，被内部视为“打赢 AI 关键战役”的核心领导人。

目前，华为的人工智能布局涵盖从底层基础设施到上层应用的产业链。

在计算基础设施方面，华为形成了基于鲲鹏的通用算力以及基于昇腾的智能算力的算力体系。

2025 年华为全联接大会上，华为发布全球最强算力超节点和集群，并罕见公布了华为芯片未来发展规划，透露华为昇腾芯片将持续演进。据机器之心，华为发布的 Atlas 950 SuperPoD 和 Atlas 960 SuperPoD 超节点，分别支持 8192 及 15488 张昇腾卡，在卡规模、总算力、内存容量、互联带宽等关键指标上全面领先。其采用的全液冷和零线缆电互联的正交架构设计，结合液冷接头浮动盲插等技术，不仅解决了超高密度下的散热和互联难题，更通过系统性创新解决了跨柜长距离、高可靠部署这一业界难题，更极大地提升了系统的长期运行可靠性和机房部署适应性。基于超节点，华为同时发布了全球最强超节点集群 Atlas 950 SuperCluster 和 Atlas 960 SuperCluster，算力规模分别为超过 50 万卡和百万卡，成为了全球最强算力集群之一。

图表9: 华为 Atlas 950 SuperPoD 超节点



资料来源: 机器之心, 国盛证券研究所

在端侧 AI 方面, 华为推出的“天工计划”承诺投入 10 亿元扶持鸿蒙 AI 生态创新, 激励超过 1 万个 AI 原生元服务与 5000+ 智能体的孵化。截至目前, 鸿蒙 5 终端设备已突破 2000 万。



智能汽车是华为在 AI 领域的重要布局方向。鸿蒙智行 8 月销量约 4.6 万辆, 前 8 个月累计销量约为 29.6 万辆。不久前, 上汽与鸿蒙智行联合打造的首款车型尚界 H5 正式上市。目前华为合作的车企包括赛力斯、奇瑞、北汽、江淮以及上汽等, 已推出问界、智界、享界、尚界、尊界等品牌。

6 快手: 可灵 2.5 Turbo 全方位升级, OpenAI 推出 Sora APP 开启 AI 视频商业化新空间

9 月 29 日可灵 2.5 Turbo 发布, 稳定性&想象力全方位升级, 视频效果再次超世代, 同时定价下调 30%。

可灵 2.5 Turbo 模型与 Veo 3 Quality、Veo 3 Fast、Seedance 1.0、Seedance 1.0 mini 等模型进行了效果对比, 可灵 2.5 Turbo 的效果表现超过了所有其他模型。

图表10: 可灵 2.5 Turbo 文生视频和图生视频效果胜负比



资料来源: 可灵 AI 公众号, 国盛证券研究所


9 月 30 日 OpenAI 推出了新的视频生成模型 Sora 2，比之前的系统更加物理精准、逼真，并且更易于控制，还支持同步对话和音效，同时推出了 Sora APP。

图表11: Sora APP



OpenAI 的 Sora ¹³⁺
OpenAI 推出的一款新视频应用
OpenAI
照片和视频类第一名
★★★★★ 3.9 • 168 个评分
自由的

iPhone 截屏



资料来源: Apple 应用商店, 国盛证券研究所

据财联社，借助这款新应用，OpenAI 在向打造社交媒体产品迈出最大一步。这让公司与 Meta 等的竞争更为直接，在此过程中，OpenAI 可能开启新的广告收入来源，同时提高技术的曝光度。

OpenAI 软件工程师 Thomas Dimson 在简报会上表示：“很多人，包括我们内部员工，一开始对 AI 生成视频流的想法都持怀疑态度。”“但新增的‘客串’功能——允许用户把自己插入视频——让团队认为这种形式‘可能对世界有益’。”他说，“我发现很多社交平台其实已经逐渐偏离了‘朋友和连接’的初衷”。

图表12: Sora APP 可以生成与朋友扳手腕的 AI 视频



资料来源：财联社，国盛证券研究所

我们认为 OpenAI 的 Sora APP 是对视频生成模型商业化变现的重要探索，有望改变未来社交平台的内容生态。快手的可灵模型性能优秀，也有望打开新的商业化成长空间。

建议关注

算力：寒武纪、海光信息、东阳光、新易盛、中芯国际、华虹半导体、胜宏科技、鸿腾精密科技、有方科技、协创数据、中际旭创、沪电股份、兴森科技、中科曙光、浪潮信息、东山精密、伟仕佳杰、宏景科技、中芯国际、奥飞数据、云赛智联、科华数据、禾盛新材、潍柴重机、金山云、浙数文化、青云、大位科技、玉柴国际、亿田智能、弘信电子、圣阳股份、润泽科技、润建股份、深信服、神州数码、深桑达、品高股份、云天励飞、优刻得、云从科技、太极股份、数据港、首都在线。

Agent：阿里巴巴、腾讯控股、拓尔思、阜博集团、第四范式、快手、美图公司、金蝶国际、金山办公、金桥信息、鼎捷数智、慧辰股份、嘉和美康、海天瑞声、泛微网络、税友股份、朗新集团、壹网壹创、润达医疗、360、万兴科技、用友网络、麦迪科技、宇信科技、京北方、中科金财、致远互联、汉得信息、软通动力、光云科技、上海钢联、新致软件、同花顺、信雅达、萤石网络、迪安诊断、中科金财、恒生电子、星环科技、卫宁健康、创业慧康、科大讯飞、万兴科技、创业黑马、迈富时、小商品城、金证股份、顶点软件、朗新集团、晶泰控股、佳发教育、新大陆、新开普等。

自动驾驶：江淮汽车、赛力斯、小鹏汽车、理想汽车、禾赛、地平线、世运电路等。

军工 AI：拓尔思、能科科技、普天科技、品高股份、海格通信、中科星图等。

风险提示

技术迭代不及预期风险：若技术迭代不及预期，则对产业链相关公司会造成一定不利影响。

经济下行超预期风险：若宏观经济景气度下行，固定资产投资额放缓，影响企业再投资意愿，从而影响消费者消费意愿和产业链生产意愿，对整个行业将会造成不利影响。

行业竞争加剧风险：若相关企业加快技术迭代和应用布局，整体行业竞争程度加剧，将会对目前行业内企业的增长产生威胁。

免责声明

国盛证券有限责任公司（以下简称“本公司”）具有中国证监会许可的证券投资咨询业务资格。本报告仅供本公司的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告的信息均来源于本公司认为可信的公开资料，但本公司及其研究人员对该等信息的准确性及完整性不作任何保证。本报告中的资料、意见及预测仅反映本公司于发布本报告当日的判断，可能会随时调整。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息及资料保持在最新状态，对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司力求报告内容客观、公正，但本报告所载的资料、工具、意见、信息及推测只提供给客户作参考之用，不构成任何投资、法律、会计或税务的最终操作建议，本公司不就报告中的内容对最终操作建议做出任何担保。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。

投资者应注意，在法律许可的情况下，本公司及其本公司的关联机构可能会持有本报告中涉及的公司所发行的证券并进行交易，也可能为这些公司正在提供或争取提供投资银行、财务顾问和金融产品等各种金融服务。

本报告版权归“国盛证券有限责任公司”所有。未经事先本公司书面授权，任何机构或个人不得对本报告进行任何形式的发布、复制。任何机构或个人如引用、刊发本报告，需注明出处为“国盛证券研究所”，且不得对本报告进行有悖原意的删节或修改。

分析师声明

本报告署名分析师在此声明：我们具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，本报告所表述的任何观点均精准地反映了我们对标的证券和发行人的个人看法，结论不受任何第三方的授意或影响。我们所得报酬的任何部分无论是在过去、现在及将来均不会与本报告中的具体投资建议或观点有直接或间接联系。

投资评级说明

投资建议的评级标准		评级	说明
评级标准为报告发布日后的 6 个月内公司股价（或行业指数）相对同期基准指数的相对市场表现。其中 A 股市场以沪深 300 指数为基准；新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为基准；香港市场以摩根士丹利中国指数为基准，美股市场以标普 500 指数或纳斯达克综合指数为基准。	股票评级	买入	相对同期基准指数涨幅在 15%以上
		增持	相对同期基准指数涨幅在 5%~15%之间
		持有	相对同期基准指数涨幅在 -5%~+5%之间
		减持	相对同期基准指数跌幅在 5%以上
	行业评级	增持	相对同期基准指数涨幅在 10%以上
		中性	相对同期基准指数涨幅在 -10%~+10%之间
		减持	相对同期基准指数跌幅在 10%以上

国盛证券研究所

北京

地址：北京市东城区永定门西滨河路 8 号院 7 楼中海地产广场东塔 7 层
 邮编：100077
 邮箱：gsresearch@gszq.com

南昌

地址：南昌市红谷滩新区凤凰中大道 1115 号北京银行大厦
 邮编：330038
 传真：0791-86281485
 邮箱：gsresearch@gszq.com

上海

地址：上海市浦东新区南洋泾路 555 号陆家嘴金融街区 22 栋
 邮编：200120
 电话：021-38124100
 邮箱：gsresearch@gszq.com

深圳

地址：深圳市福田区福华三路 100 号鼎和大厦 24 楼
 邮编：518033
 邮箱：gsresearch@gszq.com